

RAG DISCORD ASSISTANT

Kudo Assistant

Không đoán bừa. Không im lặng. Luôn có nguồn, luôn có người trả lời.

Real-time Ingestion

Grounded QA

Smart Fallback

THỰC TRẠNG

Trợ lý "Kute" cũ đang để học viên tự xoay xở

Dữ liệu tĩnh

Chỉ đọc FAQ có sẵn từ đầu — không tổng hợp được thảo luận hay deadline mới phát sinh.

Không trích dẫn nguồn

Học viên không biết thông tin lấy từ đâu để kiểm chứng lại.

Ngõ cụt

Thường tag những người chung chung, không đúng định hướng câu hỏi

GIẢI PHÁP

Kudo Assistant — RAG thời gian thực, gắn liền cộng đồng

Phá vỡ giới hạn "học vẹt" dữ liệu tĩnh, kết nối chặt chẽ giữa học viên và đội ngũ vận hành (TA/BTC).

05 • Extraction

Tự động extract từ link, file, pdf, docs, image, URL

04 • Smart Fallback

Không đoán bừa — tự động @mention đúng TA phụ trách lĩnh vực câu hỏi.

01 • Auto Ingestion

Tự động nạp tri thức từ kênh [KUDO-KNOWLEDGE] ngay khi có bài đăng mới.

02 • Human Curation

TA/BTC duyệt câu trả lời hay bằng một thả emoji  — thu hồi cũng chỉ cần bỏ thả.

03 • Grounded QA

Chỉ trả lời dựa trên dữ liệu đã nạp, kèm trích dẫn nguồn và link nhảy thẳng.

Một buổi chiều điển hình trên Discord

thong-bao-chung [KUDO-KNOWLEDGE]

BTC Ban Tổ Chức hôm nay lúc 14:02
📌 Deadline nộp Build Phase dời sang **23:59 ngày 05/08** . Nộp qua form cũ.

✓ ĐÃ NẠP VÀO TRI THỨC KUDO · TỨC THỜI

HV Học viên
Deadline Build Phase là ngày nào vậy Kudo?

K Kudo Bot
Deadline Build Phase là **23:59 ngày 05/08**, nộp qua form cũ.
↳ nguồn: #thong-bao-chung · BTC · [Xem tin nhắn gốc ↗](#)

Duyệt tri thức bằng emoji

TA thả 🟢 vào câu trả lời hay của bất kỳ ai → Kudo tự tổng hợp ngữ cảnh, biến thành tri thức chính thức.

Câu hỏi ngoài phạm vi

"Có được đổi nhóm sau khi nộp không ạ?" → Kudo nhận diện chưa có dữ liệu, tự @mention **@TA-Nguyen (Vận hành)** vào hỗ trợ.

/tong_hop days:3

Tóm tắt toàn bộ deadline & thông báo quan trọng 3 ngày qua — chỉ trong 1 giây.

Kiến trúc nhỏ gọn, dễ triển khai, khó bịa đặt

Tech Stack

Bot Framework	Python · discord.py
Vector DB	ChromaDB (Client-Server)
LLM	Gemini 2.5 Flash
Embedding	Gemini Embedding

Micro-service linh hoạt

Cấu hình chạy độc lập qua Gemini API — dễ mở rộng, dễ thay thế mô hình.

Grounded-by-design

Không có ngữ cảnh liên quan → Kudo từ chối đoán, chuyển sang Fallback thay vì bịa.

TỔNG KẾT

Từ trợ lý hay đoán bừa, đến người đồng đội đáng tin

Real-time

Tri thức cập nhật ngay khi có thông báo mới — không còn học vẹt dữ liệu cũ.

Đáng tin cậy

Mọi câu trả lời có trích dẫn nguồn và link gốc — học viên tự kiểm chứng được.

Không ai bị bỏ lại

Câu hỏi khó luôn được chuyển đến đúng người — TA/BTC không bỏ sót yêu cầu.

Từ MVP đến trợ lý toàn diện cho cộng đồng

HIỆN TẠI

MVP v1.0

Ingestion, Curation, Grounded QA, Fallback, Tổng hợp — vận hành trong một server.

GIAI ĐOẠN KẾ

Đa server

Nhân rộng Kudo cho nhiều khoá học / cộng đồng cùng lúc, mỗi server một "não" riêng.

SẮP TỚI

Dashboard cho BTC

Theo dõi câu hỏi chưa trả lời được, chủ đề nóng, hiệu suất từng TA.

TẦM NHÌN

Trợ lý học tập chủ động

Chủ động nhắc deadline, gợi ý tài liệu theo tiến độ học của từng học viên.